



**UNIVERSIDAD AUTÓNOMA DE YUCATÁN
FACULTAD DE MATEMÁTICAS**

Minería de Datos

M. en C. Ernesto Antonio Guerrero Lara



Proyecto Final:

Clasificación de Tumores Benignos vs Malignos

Especialidad en Estadística

27 de Mayo 2025

Alumno: Amir Oswaldo Canto Palomo

Algoritmo: Árboles de Decisión

1. Introducción

Descripción de la Base de Datos

La base de datos "Tumor" contiene información de 569 casos de tumores de mama con 32 variables. La variable objetivo es **diagnosis** que clasifica los tumores como:

- **B:** Benigno (no canceroso)
- **M:** Maligno (canceroso)

Las características incluyen medidas de:

- **Mean (promedio):** radio, textura, perímetro, área, suavidad, compacidad, concavidad, puntos cóncavos, simetría y dimensión fractal
- **SE (error estándar):** de las mismas medidas
- **Worst (peor valor):** de las mismas medidas

Código R para Análisis Exploratorio

```
library(rpart)

library(rpart.plot)

library(caret)

library(dplyr)

datos <- read.csv(file.choose(), stringsAsFactors = FALSE)

cat("Dimensiones del dataset:", dim(datos), "\n")

cat("Estructura de los datos:\n")

str(datos)
```

```
summary(datos[, c("diagnosis", "radius_mean",  
"texture_mean", "area_mean")])
```

```
table(datos$diagnosis)
```

```
prop.table(table(datos$diagnosis)) * 100
```

Resumen Estadístico

- **Total de casos:** 569 tumores
- **Variables predictoras:** 31 características numéricas
- **Variable objetivo:** diagnosis (B/M)
- **Distribución real:** 62.74% benignos (357 casos), 37.26% malignos (212 casos)
- **División de datos:** 399 casos para entrenamiento, 170 casos para prueba
- **Valores faltantes:** 0 (base de datos completa)

2. Algoritmo Seleccionado: Árboles de Decisión

Justificación de la Selección

1. Los árboles de decisión generan reglas fáciles de entender para el general de las personas.
2. Los árboles seleccionan las variables más importantes.
3. A diferencia de otros algoritmos no requiere un procesamiento complejo (como normalización o reducción de los datos).
4. Las decisiones del árbol se pueden mostrar gráficamente.

Manipulación de la Base de Datos

```
datos <- datos[, -1]

datos$diagnosis <- as.factor(datos$diagnosis)

cat("Valores faltantes por columna:\n")

colSums(is.na(datos))


set.seed(123)
indice_entrenamiento <- createDataPartition(datos$diagnosis,
p = 0.7, list = FALSE)

datos_entrenamiento <- datos[indice_entrenamiento, ]

datos_prueba <- datos[-indice_entrenamiento, ]


cat("Tamaño conjunto entrenamiento:",
nrow(datos_entrenamiento), "\n")

cat("Tamaño conjunto prueba:", nrow(datos_prueba), "\n")
```

Construcción del Modelo

```
r

# Entrenar el árbol de decisión
```

```

modelo_arbol <- rpart(diagnosis ~ .,
                      data = datos_entrenamiento,
                      method = "class",
                      control = rpart.control(cp = 0.01,
minsplit = 10))

print(modelo_arbol)

rpart.plot(modelo_arbol,
           main = "Árbol de Decisión Clasificación de
Tumores",
           extra = 2,
           type = 4,
           fallen.leaves = TRUE)

importancia <- modelo_arbol$variable.importance
head(sort(importancia, decreasing = TRUE), 10)

```

3. Validación del Algoritmo

Predicciones y Matriz de Confusión

```

r

predicciones <- predict(modelo_arbol, datos_prueba, type =
"class")

matriz_confusion <- confusionMatrix(predicciones,
datos_prueba$diagnosis)

print(matriz_confusion)

```

```

tabla <- table(Predicho = predicciones, Real =
datos_prueba$diagnosis)

print(tabla)

accuracy <- sum(diag(tabla)) / sum(tabla)

sensitivity <- tabla[2,2] / sum(tabla[,2]) # Sensibilidad (
Maligno)

specificity <- tabla[1,1] / sum(tabla[,1]) # Especificidad
(para Benigno)

precision <- tabla[2,2] / sum(tabla[2,]) # Precisión para
Maligno

cat("Exactitud (Accuracy):", round(accuracy * 100, 2),
"%\n")

cat("Sensibilidad:", round(sensitivity * 100, 2), "%\n")

cat("Especificidad:", round(specificity * 100, 2), "%\n")

cat("Precisión:", round(precision * 100, 2), "%\n")

```

Análisis del Modelo

```

r

cat("Variables más importantes en el modelo:\n")

importancia_ordenada <-
sort(modelo_arbol$variable.importance, decreasing = TRUE)

print(head(importancia_ordenada, 8))

cat("\nProfundidad del árbol:", max(modelo_arbol$frame$var
== "<leaf>"))

cat("\nNúmero total de nodos:", nrow(modelo_arbol$frame))

```

```
cat("\nNúmero de hojas (nodos finales):",  
sum(modelo_arbol$frame$var == "<leaf>"))
```

Interpretación de Resultados Esperados

- **Exactitud esperada:** 90-95%
 - **Sensibilidad:** >90% (importante para detectar tumores malignos)
 - **Especificidad:** >85% (evitar falsos positivos)
 - **Variables más importantes:** Probablemente `concave.points_worst`, `perimeter_worst`, `concavity_mean`
-

4. Conclusiones

Resultados del Modelo

El árbol de decisión mostró un rendimiento sólido para la clasificación de tumores:

1. **Exactitud del 89.41%:** Clasificó correctamente 152 de 170 casos en el conjunto de prueba
2. **Excelente especificidad (93.46%):** Muy bueno identificando tumores benignos, minimizando falsos positivos
3. **Sensibilidad aceptable (82.54%):** Detectó la mayoría de tumores malignos, aunque hay margen de mejora
4. **Variables clave identificadas:** El modelo se basa principalmente en medidas de área, radio y perímetro en sus valores "worst"

Análisis de la Matriz de Confusión

```
Real  
  
Predicho   B   M  
  
B 100  11  <- 11 falsos negativos (tumores malignos  
no detectados)  
  
M   7  52  <- 7 falsos positivos (tumores benignos  
clasificados como malignos)
```

Interpretación clínica:

- **Falsos negativos (11 casos):** Tumores malignos no detectados - requiere atención médica
- **Falsos positivos (7 casos):** Tumores benignos clasificados como malignos - causan ansiedad innecesaria pero son menos críticos

Variables Más Importantes Identificadas

El análisis reveló que las características morfológicas en sus "peores valores" son las más discriminativas:

- **Área, radio y perímetro "worst":** Representan las medidas más extremas del tumor
- **Medidas promedio:** área_mean, perimeter_mean, radius_mean complementan la información
- **Puntos cóncavos:** points_worst también contribuye significativamente

Ventajas del Modelo Obtenido


- **Simplicidad interpretativa:** Solo 5 reglas de decisión finales
- **Variables relevantes:** Se enfoca en características morfológicas clínicamente significativas
- **Especificidad excelente:** 93.46% minimiza procedimientos innecesarios
- **Eficiencia computacional:** Predicciones rápidas con reglas simples

Limitaciones Identificadas

- **Sensibilidad mejorable:** 82.54% significa que 1 de cada 6 tumores malignos podría no detectarse
- **Falsos negativos:** 11 casos requieren atención especial en implementación clínica
- El modelo es sensible a la precisión de las mediciones morfológicas

Conclusión

Árbol de Decisión Clasificación de Tumores



Este modelo puede servir como **herramienta inicial** especialmente útil para:

- Priorizar casos que requieren evaluación urgente
- Reducir carga de trabajo en análisis de rutina
- Identificar patrones morfológicos relevantes

El presente algoritmo se puede usar como apoyo diagnóstico, pero siempre complementar con criterio médico profesional.